2. Wstęp do analizy numerycznej

Podstawowe pojęcia

W ciągu minionych kilku stuleci opracowano wiele metod analizy matematycznej do poprawnego formułowania i rozwiązywania zadań matematycznych występujących w modelowaniu. Niestety, zdecydowana większość dokładnych modeli nie posiada rozwiązania analitycznego. Modele te wymagają przyjęcia dodatkowych założeń i ograniczeń prowadzących do prostszych zadań matematycznych, tak aby rozwiązanie otrzymanych modeli przybliżonych można było wyrazić w postaci zwykłych wzorów algebraicznych lub za pomocą znanych funkcji analitycznych. Przykładem takich postępowań jest sprowadzenie problemu nieliniowego do zwykłego układu równań liniowych (przybliżenie liniowe).

Inne podejście do problemów nierozwiązywalnych analitycznie polega na przeprowadzeniu wielu prostych operacji obliczeniowych mających na celu bezpośrednie otrzymanie przybliżonej wartości liczbowej (numerycznej) rozwiązania dla modelu dokładnego. Przed powstaniem współczesnych komputerów obliczenia numeryczne wykonywano jedynie ręcznie lub przy pomocy arytmometrów, stąd zastosowanie obejmowało jedynie nieliczne, stosunkowo proste zadania matematyczne, których rozwiązywanie numeryczne wymaga przeprowadzenia niedużej liczby operacji. Wraz z rozwojem sprzętu i technik komputerowych nastąpił gwałtowny wzrost zainteresowania obliczeniami numerycznymi. Obecnie komputery dużej mocy obliczeniowej pozwalają rozwiązywać numerycznie bardzo szerokie spektrum dokładnych modeli matematycznych.

Analiza numeryczna zajmuje się opracowaniem i badaniem metod numerycznego rozwiązywania zadań matematycznych. Przez metodę numeryczną rozumiemy ciąg operacji elementarnych na liczbach prowadzących do otrzymania przybliżonej wartości liczbowej rozwiązania

pewnego problemu matematycznego. Z oczywistych powodów metodami numerycznymi daje się rozwiązać jedynie zadania, w których dane i wyniki są liczbami. W ogólności rozpatrywane zadanie może również posiadać rozwiązanie analityczne. W takim przypadku metoda numeryczna służy jedynie do obliczenia wartości liczbowej na podstawie wzoru określającego wynik zadania. Jednakże najczęściej metody numeryczne stosuje się do problemów nierozwiązywalnych analitycznie.

➡ Do elementarnych operacji numerycznych zaliczamy przede wszystkim działania arytmetyczne na liczbach (dodawanie, odejmowanie, mnożenie, dzielenie oraz negacja, czyli zmiana znaku liczby). Większość współczesnych procesorów w systemach komputerowych udostępnia jako operacje elementarne również rozkazy wywołania podstawowych funkcji matematycznych, np. pierwiastek kwadratowy, logarytm, główne funkcje trygonometryczne. Jednakże otrzymanie wartości tych funkcji nie jest zupełnie elementarne, gdyż wymaga wykonania przez procesor odpowiednich złożonych obliczeń numerycznych, sprowadzających się do ciągu działań arytmetycznych. Załóżmy zatem, że zbiór elementarnych operacji numerycznych dostępnych w wybranym urządzeniu liczącym obejmuje jedynie podstawowe działania arytmetyczne (np. arytmometr, prosty kalkulator). Wybór taki w zasadzie nie ogranicza możliwości i zastosowań metod numerycznych, gdyż większość metod (jeśli nie wszystkie) daje się przedstawić jako ciąg działań arytmetycznych na liczbach. Realizacja metody numerycznej w postaci programu komputerowego wymaga dodatkowo zastosowania innych operacji, takich jak odczyt/zapis danych i wyników obliczeń, relacje, działania logiczne, instrukcje decyzyjne, iteracyjne.

➡ Ponadto zakładamy, że wszystkie operacje przeprowadza się na liczbach skończonej precyzji, tzn. takich, których zapis (mantysa) składa się maksymalnie ze skończonej (niewielkiej) ilości cyfr. Założenie takie jest oczywiście spełnione we wszystkich cyfrowych urządzeniach obliczeniowych (arytmometrach, kalkulatorach, komputerach itp.), w których rozmiar rejestrów z danymi jest ograniczony, stąd ograniczona jest również dokładność arytmetyki. Liczby wprowadzane do urządzenia i otrzymywane w trakcie obliczeń, gdy przekraczają dopuszczalną długość, są skracane poprzez ucinanie lub zaokrąglanie. Stanowi to jedno ze źródeł błędów w obliczeniach.

➡ Metody numeryczne dzielimy na metody ścisłe i przybliżone. Metoda ścisła umożliwia uzyskanie rozwiązania danego zadania po wykonaniu

skończonego ciągu operacji elementarnych. Jedynym źródłem niedokładności w takiej metodzie są zaokrąglenia/ucinania wynikające ze skończonej precyzji przetwarzanych liczb. Większość metod ścisłych dotyczy zadań z zakresu algebry liniowej.

Przykład 1.1

Zadanie polega na rozwiązaniu prostego równania liniowego:

$$ax + b = 0$$

gdzie dane wejściowe dla zadania są następujące[1]:

$$a = 3.21 \quad b = 1.23$$

Zadanie posiada rozwiązanie analityczne wyrażone odpowiednim wzorem algebraicznym. Stąd na podstawie wzoru na wynik zadania:

$$x^{(s)} = -b / a$$

możemy sformułować prostą metodę numeryczną, dzięki której uzyskamy wartość liczbową wyniku. Metoda ta składa się jedynie z dwóch operacji elementarnych: negacji oraz dzielenia, stąd jest to metoda ścisła. W wyniku otrzymujemy dokładną wartość liczbową (okresową):

$$x^{(s)} = 2.6097560975...$$

Jeżeli urządzenie liczące operuje na liczbach posiadających maksymalnie trzy cyfry mantysy (różne od wiodących i końcowych zer w zapisie liczby), wtedy p/w wynik zostanie zaokrąglony do dwóch cyfr po kropce:

$$x^{(s)} \approx 2.61$$

co powoduje powstanie jedynego błędu numerycznego w obliczeniach.

[1] W dalszym ciągu wykładów będziemy posługiwać się kropką dziesiętną w zapisie liczb rzeczywistych, co jest stosowane w większości języków programowania.

Innym przykładem metody ścisłej jest *metoda eliminacji Gaussa*, stosowana do rozwiązywania układu *n* równań liniowych z *n* niewiadomymi. Niestety, większości zadań nie daje się rozwiązać metodami ścisłymi. Szersze zastosowanie mają zatem metody przybliżone. Do metod przybliżonych zaliczamy takie, w których uzyskanie rozwiązania możliwe jest po wykonaniu nieskończenie wielu operacji. Ponieważ w praktyce nie jest możliwe wykonanie wszystkich operacji w nieskończonym ciągu, więc obliczenia ograniczone są jedynie do skończonej (niewielkiej) liczby operacji, co w efekcie prowadzi do uzyskania wyniku przybliżonego. Z metodą przybliżoną związany jest zatem pewien błąd, który pojawia się niezależnie od precyzji (skracania) stosowanych w obliczeniach liczb. Błąd ten nazywamy błędem obcięcia lub błędem aproksymacji.

Do sformułowania metod przybliżonych najczęściej stosuję się ideę iteracji (łac. *iteratio* - powtarzanie), czyli kolejnych przybliżeń. Iteracja oznacza krokowe powtarzanie pewnego wzorcowego procesu obliczeniowego, przy czym dane wejściowe do obliczeń w bieżącym kroku są wynikami obliczeń z kroku poprzedniego. Czasami pojęciem iteracji określa się również obliczenia wykonywane w jednym kroku metody iteracyjnej.

Przykład 1.2

Zadanie polega na rozwiązaniu prostego równania kwadratowego:

$$x^2 - b = 0$$

gdzie dane dla zadania są następujące:

$$b = 2.0$$

Wykorzystując formalny wzór na wynik zadania w ogólnej postaci

$$x^{(s)} = \sqrt{b}$$

widzimy, iż rozwiązanie numeryczne sprowadza się jedynie do wywołania funkcji pierwiastka kwadratowego z argumentem *b* (funkcja ta zwykle oznaczona jest identyfikatorem **sqrt**). Metoda ta działa pod warunkiem, iż pierwiastkowanie jest operacją elementarną w stosowanym urządzeniu

liczącym. W przeciwnym razie (np. w przypadku arytmometru lub prostego kalkulatora) należy sformułować bardziej złożoną metodę numeryczną. W tym celu doprowadźmy p/w równanie do postaci

$$x = F(x) := \alpha\, x + \ldots$$

Po prostych przekształceniach otrzymujemy:

$$x^2 - b = 0 \;/ : x \quad \Rightarrow \quad x - b/x = 0 \quad \Rightarrow \quad 2x - x - b/x = 0$$
$$\Rightarrow \quad 2x = x + b/x \quad \Rightarrow \quad x = 0.5\left(x + b/x\right)$$

Okazuje się, że równanie w takiej postaci można skutecznie i szybko rozwiązać numerycznie stosując metodę iteracyjną. Obliczenia wykonywane w bieżącym kroku metody zapisujemy w postaci wzoru, który jednocześnie definiuje nieskończony ciąg liczb,

$$x_{n+1} = F(x_n) := 0.5\left(x_n + b/x_n\right)$$

gdzie n = 0,1,2,3,... . Jeżeli ciąg liczb x_n jest zbieżny, to jego granica jest szukanym rozwiązaniem równania:

$$x^{(s)} = \lim_{n\to\infty} x_n$$

A zatem otrzymana metoda zawiera nieskończenie wiele kroków obliczeniowych, stąd jest to metoda przybliżona. Zauważmy, że w metodzie tej wykonujemy jedynie trzy działania arytmetyczne na każdy krok iteracji: dzielenie, dodawanie i mnożenie.
Dla przypadku b = 2.0 szukane rozwiązanie jest pierwiastkiem kwadratowym z dwóch (1.4142...). Ciąg operacji numerycznych rozpoczynamy od podanego na wejściu przybliżenia zerowego tego pierwiastka, np.:

$$x_0 = 1.5$$

a następnie otrzymujemy przybliżenie pierwszego rzędu,

$$x_1 = 0.5\left(x_0 + b/x_0\right) = 0.5\left(1.5 + 2.0/1.5\right) = 1.4167$$

stąd otrzymujemy przybliżenie drugiego rzędu:

$$x_2 = 0.5\left(x_1 + b / x_1\right) = 0.5\left(1.4167 + 2.0 / 1.4167\right) = 1.414216$$

i tak dalej.
Otrzymany wynik przybliżony możemy porównać z wartością tablicową (dokładną) pierwiastka z dwóch:

$$x^{(s)} = \sqrt{2} = 1.414214...$$

Widać, że już przybliżenie drugiego rzędu różni się od wartości dokładnej dopiero na szóstym miejscu po kropce. Zbieżność metody zależy w dużym stopniu od wzoru definiującego iterację, a także w pewnym stopniu od wyboru przybliżenia zerowego. Podana wyżej metoda obliczania pierwiastka kwadratowego **sqrt** jest powszechnie wykorzystywana w komputerach i kalkulatorach.

Wartości podstawowych funkcji matematycznych, takich jak **exp**, **log**, **sin**, **cos** itp., można wyznaczyć numerycznie w sposób podobny do obliczania pierwiastka kwadratowego z przykładu 1.2. W systemach komputerowych algorytmy numerycznego wyznaczania wartości tych funkcji są zwykle zaimplementowane w postaci procedur należących do biblioteki standardowej języka programowania. Niektóre funkcje są obliczane numerycznie bezpośrednio przez współczesne procesory (może to być osobny koprocesor arytmetyczny, np. Intel 8087, lub jednostka matematyczna, np. w procesorze PENTIUM). W dalszym ciągu wykładów zakładać będziemy, że zbiór elementarnych operacji numerycznych obejmuje również p/w funkcje.

Przykład 1.3

Zastosować metodę kolejnych przybliżeń do otrzymania wartości przybliżonej dla rozwiązania następującego równania:

$$2\sin x - x = 0$$

W tym przypadku nie jest znany formalny wzór określający rozwiązanie, co oznacza, że jest to przykład równania nierozwiązywalnego analitycznie. Metody numeryczne należy zatem stosować od początku (łac. *ab initio*) , czyli w odniesieniu do równania w oryginalnej postaci.

Prosta metoda iteracyjna dla tego równania zdefiniowana jest wzorem:

$$x_{n+1} = 2\sin x_n$$

Dla wartości początkowej

$$x_0 = \frac{\pi}{2} \approx 1.57$$

uzyskujemy ciąg zbieżny, który dopiero po dwudziestu krokach daje wartość przybliżoną dla szukanego rozwiązania

$$x^{(s)} \approx x_{20} = 1.8955$$

z dokładnością do pięciu cyfr znaczących. Widać, iż metoda ta nie jest szybko zbieżna. Należy tu zastosować bardziej zaawansowane metody rozwiązywania równań nieliniowych.

Dokładność obliczeń numerycznych

Rozwiązania numeryczne pewnego problemu matematycznego uzyskane dowolnymi metodami (ścisłymi lub przybliżonymi) są zawsze obarczone pewnym błędem obliczeń, a zatem różnią się od wyników dokładnych. Zadaniem analizy (teorii) błędów jest podanie źródeł i wartości błędów związanych z obliczeniami numerycznymi. Niestety, w praktyce ścisłe określenie wartości błędu nigdy nie jest możliwe; możemy jedynie błąd ten oszacować, czyli podać jego górne ograniczenie.

Dla dowolnych obliczeń numerycznych wyróżniamy następujące główne źródła błędów:

- **błędy pomiarowe (początkowe, wejściowe)** - dane wprowadzane do obliczeń mogą być wynikiem pomiarów fizycznych obarczonych niedokładnością urządzeń pomiarowych;
- **błędy zapisu liczb (zaokrąglenia/ucinania)** - liczby rzeczywiste zarówno wejściowe, jak i powstałe w trakcie obliczeń mogą być w zapisie skracane poprzez zaokrąglenie lub poprzez ucinanie do

liczb zawierających ustaloną ilość cyfr mantysy, co zwykle związane jest ze skończoną dokładnością maszyn liczących;

- **błędy metody (obcięcia, aproksymacji)** - nieskończony ciąg operacji w metodach przybliżonych jest obcinany przed osiągnięciem wartości dokładnej rozwiązania; w trakcie formułowania metody obliczeń dokładne wyrażenie może być aproksymowane przez wyrażenie prostsze.

Błędy pomiarowe dotyczą dokładności danych wejściowych i wobec tego są poza kontrolą w trakcie obliczeń - teoria błędów obliczeń numerycznych nie zajmuje się nimi.

Natomiast błędy zaokrągleń związane ze skończoną precyzją urządzeń wykonujących obliczenia można jedynie do pewnego stopnia kontrolować. Na ogół precyzja współczesnych komputerów jest na tyle duża, że maszynowe błędy zaokrągleń są mało widoczne. Jednakże w przypadku długotrwałych obliczeń oraz w przypadku metod wyjątkowo wrażliwych (niestabilnych) skutki zaokrągleń mogą być bardzo dotkliwe.

Uwaga: W przypadku najczęściej stosowanej arytmetyki zmiennopozycyjnej IEEE w komputerach liczby rzeczywiste reprezentowane są przez podanie cechy i mantysy. Na przykład liczba $0.00503 \equiv 5.03 \cdot 10^{-3}$ posiada cechę -3 oraz mantysę 5.03, natomiast liczba $67100 \equiv 6.71 \cdot 10^{4}$ posiada cechę 4 oraz mantysę 6.71. Ponieważ cecha i mantysa są zapamiętywane w rejestrach o skończonym rozmiarze, więc ilość cyfr tych wielkości jest ograniczona. Na przykład w procesorach PENTIUM cecha posiada maksymalnie 4 cyfry, a mantysa około 15 ÷ 18. Skracania liczb i niedokładność arytmetyki w komputerze jest skutkiem ograniczenia długości mantysy. Natomiast skończona ilość cyfr cechy powoduje jedynie ograniczenie zakresu liczb rzeczywistych. Zagadnienia związane z arytmetyką komputerową zostały szerzej opisane w dalszej części kursu.

Przykład 1.4

Niech precyzja urządzenia liczącego dopuszcza liczby posiadające maksymalnie trzy cyfry mantysy w zapisie dziesiętnym. Wtedy dane wejściowe dla pewnego procesu obliczeniowego

$$a = 0.020700 \quad b = 1.23632 \quad c = 704.121$$

zostaną zaokrąglone do liczb:

$$a = 0.0207 \quad \widetilde{b} = 1.240 \quad \widetilde{c} = 704.0$$

Jedynie dane b i c ulegną zmianie, a związane z tym maksymalne błędy zaokrągleń wyniosą:

$$\left|b - \widetilde{b}\right| = 0.00368 \le 0.004 = \Delta b \qquad \left|c - \widetilde{c}\right| = 0.121 \le 0.2 = \Delta c$$

Jeżeli urządzenie skraca liczby poprzez ucinanie, to wtedy dana b przyjmie wartość przybliżoną z większym błędem:

$$\widetilde{b} = 1.230 \quad 0.00632 \le 0.007 = \Delta b$$

Na ogół jednak będziemy zakładać, że skracanie odbywa się poprzez zaokrąglenie. Dokładna definicja operacji zaokrąglenie zostanie podana na zajęciach laboratoryjnych (patrz uwaga do zadania 4).

Uwaga: W praktyce pomiarów laboratoryjnych jak również obliczeń numerycznych przy zapisie błędów stosuje się następujące zasady. Pierwotną wartość błędu (oszacowaną z pomiarów lub obliczeń) zapisujemy w postaci zaokrąglonej liczby z dokładnością do dwóch kolejnych cyfr różnych od zera. Zaokrąglanie błędu wykonujemy zawsze w górę. Błąd dwucyfrowy możemy jeszcze dalej zaokrąglić do pierwszej cyfry, co w pomiarach laboratoryjnych na ogół wykonuje się jedynie wtedy, gdy na skutek tego zaokrąglenie zmiana wartości błędu nie przekracza 10% wartości dwucyfrowej. Na przykład błąd dwucyfrowy 0.012 zgodnie z tą zasadą nie zaokrągla się do wartości jednocyfrowej 0.02 , gdyż zmiana ta wynosi 67% z wartości 0.012 i znacznie przekracza umowny próg 10%, co niepotrzebnie zmniejsza dokładność w zapisie wyników pomiarów (pomiary na ogół wykonuje się ze dobrze znaną, dużą dokładnością). W praktyce numerycznej zwykle podaje się błędy jednocyfrowe ze względu na brak ścisłej informacji o dokładności obliczeń i stąd grube oszacowanie ich błędów.

Najwięcej prac w analizie błędów obliczeń numerycznych poświęconych jest oszacowaniu błędów obcięcia/aproksymacji ze względu na ich bezpośredni związek z zastosowaną metodą numeryczną. Dla niektórych metod błąd ten można dość łatwo oszacować. Na ogół jednakże określenie błędu metody jest zadaniem bardzo trudnym.

Niech dana będzie pewna wielkość A (dana wejściowa lub wynik obliczeń) o wartości dokładnej a będącej dowolną liczbą rzeczywistą. Wskutek istnienia źródeł błędów otrzymujemy wartość przybliżoną $\widetilde{a}$ tej wielkości. W teorii błędów wprowadza się następujące pojęcia:

- **błąd bezwzględny maksymalny**

$$\Delta a \geq \left| a - \widetilde{a} \right|$$

- **błąd względny maksymalny**

$$\delta a = \frac{\Delta a}{|\widetilde{a}|}$$

Wartość dokładna a danej wielkości jest prawie zawsze nieznana, jednakże znajomość wartości przybliżonej $\widetilde{a}$ i błędu bezwzględnego Δa pozwala podać minimalny przedział obejmujący szukaną wartość dokładną:

$$\widetilde{a} - \Delta a \leq a \leq \widetilde{a} + \Delta a$$

Fakt ten często zapisujemy w postaci tzw. liczby przybliżonej:

$$a = \widetilde{a} \pm \Delta a$$

Błąd względny δa, określany najczęściej w procentach, podaje, jaka część wartości przybliżonej $|\widetilde{a}|$ danej wielkości stanowi jej błąd bezwzględny Δa. Ze względu na brak znajomości wartości dokładnej a błąd ten zwykle odnosimy do wartości przybliżonej. Gdy błąd jest niewielki i obie wartości są bliskie sobie $\widetilde{a} \approx a$, stosujemy zapis w postaci tzw. liczby zaburzonej:

$$\widetilde{a} = a(1 \pm \varepsilon)$$

gdzie dodatnia (niewielka) liczba ε jest miarą pewnego zaburzenia wartości dokładnej prowadzącego do powstania wartości przybliżonej danej wielkości; liczba ta jest dokładnie równa błędowi względnemu $\varepsilon = \delta a$, gdy w mianowniku jego definicji występuje $|a|$.

Uwaga: Istnienie niezerowego błędu, z jakim wyznaczamy daną wielkość, powoduje, że zapis jej wartości przybliżonej nie należy podawać z dowolną ilością cyfr. Należy jedynie uwzględniać tzw. cyfry znaczące, nieobarczone błędem, ponieważ dalsze cyfry nie są już pewne. Ciąg cyfr znaczących w zapisie danej wartości przybliżonej kończy się na rzędzie, z dokładnością do którego podano dany błąd. W szczególności ciąg ten może zawierać na swym końcu zera, z drugiej strony do cyfr znaczących nie zaliczamy wiodących zer w zapisie liczby. W celu zwiększenia informacji można podawać jedną lub dwie z początkowych cyfr niepewnych występujących za cyframi znaczącymi; cyfry niepewne

ujmuje się zwykle w nawiasy okrągłe. Na przykład liczba 0.010(3) ± 0.006 zawiera dwie cyfry znaczące 1 i 0 oraz jedną cyfrę niepewną 3. Bardziej dokładna metoda wyznaczania cyfr znaczących w zapisie danej wartości przybliżonej na podstawie jej błędu zostanie podana na zajęciach laboratoryjnych (patrz uwaga do zadania 5).

Przykład 1.5

Niech dane będzie liczba przybliżona:

$$a = 1.24 \pm 0.004$$

Z zapisu tego wynika, że nieznana wartość dokładna a wielkości A leży w przedziale ufności od 1.236 do 1.244. Ponadto, wartość przybliżona 1.24 tej wielkości podana jest z dokładnością do trzech cyfr znaczących 1,2,4. Cyfry występujące za cyfrą 4 są już niepewne. Ale ponieważ w przedziale ufności nie zmieniają się jedynie dwie cyfry 1 i 2 (od 1.236 do 1.244), więc w bardziej ścisłych opisach podaje się jako znaczące tylko te dwie cyfry, zaś cyfrę 4 traktuje się już jako niepewną. Ponadto, z błędu względnego 0.003 tej wielkości wynika, iż 0.3% wartości przybliżonej 1.24 to błąd bezwzględny 0.004 tej wielkości. Wartość przybliżoną 1.24 tej wielkości możemy również traktować jako pewne zaburzenie:

$$1.24 = a(1 \pm 0.003)$$

nieznanej wartości dokładnej.